

# 行列輪講: 第 6 回 確率分布, ガウス積分

杉浦 圭祐

慶應義塾大学理工学部情報工学科 松谷研究室

August 14, 2023

# 目次

① 概要

② 確率分布

③ ガウス積分

# 目次

## ① 概要

## ② 確率分布

## ③ ガウス積分

# このスライドの概要

- 確率分布と、ガウス積分について確認する
  - 確率密度関数, ベイズの定理, モーメント
  - エントロピー, KL ダイバージェンス, 相互情報量
  - 不偏推定量, クラメール・ラオ (Cramér–Rao) の下限
  - 積分の変数変換, 偶関数と奇関数の積分, ガウス積分
- 以下の資料を参考に作成しました:
  - パターン認識と機械学習 (上巻)
  - State Estimation For Robotics

# 目次

① 概要

② 確率分布

③ ガウス積分

# 確率密度関数 (Probability Density Function; PDF)

- 確率変数  $x$  が, ある確率密度関数  $p(x)$  に従うとする.
- $p(x)$  は,  $[a, b]$  の範囲で定義されるとする.
- $p(x)$  は, 2 つの条件を満たす:


$$p(x) \geq 0, \quad \int_a^b p(x) dx = 1$$

# 確率密度関数と確率

- 確率密度と確率は別物である.
- $x$  が,  $[c, d]$  の範囲をとる**確率**を,  $\Pr(c \leq x \leq d)$  とする.

$$\Pr(c \leq x \leq d) = \int_c^d p(x) dx$$

- $\Pr(c \leq x \leq d)$  は, 以下の図で, 影がかかった部分である.



# 条件付き確率分布 (Conditional Probability)

- 確率変数  $x \in [a, b]$ ,  $y \in [r, s]$  を考える.
- $y$  に条件付けられた,  $x$  の確率密度関数  $p(x | y)$  を考える.
- $p(x | y)$  を, **条件付き確率密度関数** という.
- $p(x | y)$  も, 2 つの条件を満たす:

$$p(x | y) \geq 0, \quad \int_a^b p(x | y) dx = 1$$



# 同時分布 (Joint Probability)

- 複数の確率変数  $x_1, x_2, \dots, x_N$  を考える ( $x_i \in [a_i, b_i]$ ).
- これらの確率密度関数  $p(x_1, x_2, \dots, x_N)$  を考える.
- $p(x_1, x_2, \dots, x_N)$  を, **同時確率密度関数**という.
- 確率変数をまとめて,  $\mathbf{x} = (x_1, x_2, \dots, x_N)$  とかく.
- $p(\mathbf{x})$  も, 2 つの条件を満たす:

$$p(\mathbf{x}) = p(x_1, x_2, \dots, x_N) \geq 0$$
$$\int_{\mathbf{a}}^{\mathbf{b}} p(\mathbf{x}) d\mathbf{x} = \int_{a_N}^{b_N} \cdots \int_{a_1}^{b_1} p(x_1, \dots, x_N) dx_1 \cdots dx_N = 1$$

- 積分の範囲は  $\mathbf{a} = (a_1, a_2, \dots, a_N)$ ,  $\mathbf{b} = (b_1, b_2, \dots, b_N)$  である.
- 確率変数の範囲については, 以後は明記しない.

# 加法定理 (Sum Rule), 周辺化 (Marginalization), 乗法定理

- 確率変数  $\mathbf{x}, \mathbf{y}$  を考える.
- 同時分布  $p(\mathbf{x}, \mathbf{y})$  と, **周辺分布**  $p(\mathbf{x})$  について, 次が成り立つ.
- 加法定理**, **周辺化**, **積分消去**とよばれる.

$$p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{y}) d\mathbf{y}$$

- 同時分布  $p(\mathbf{x}, \mathbf{y})$ , 条件付き確率分布  $p(\mathbf{x} | \mathbf{y})$ ,  $p(\mathbf{y} | \mathbf{x})$ , 周辺分布  $p(\mathbf{x})$ ,  $p(\mathbf{y})$  について, 次が成り立つ.
- 乗法定理**とよばれる.

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x} | \mathbf{y})p(\mathbf{y}) = p(\mathbf{y} | \mathbf{x})p(\mathbf{x})$$

- 同時分布は, 周辺分布と, 条件付き確率分布に**分解**できる.

# 独立 (Independent)

- 確率変数  $x, y$  を考える.
- $x, y$  が**独立**であるとする.
- $y$  は  $x$  の確率分布に ( $x$  は  $y$  の確率分布に) 影響を与えない.
- 条件付き確率分布  $p(x | y)$  は,  $p(x)$  に等しい.
  - $y$  が与えられても,  $x$  についての確率分布は変化しない.
- 同様に,  $p(y | x)$  は,  $p(y)$  に等しい.
- 同時分布  $p(x, y)$  を, 個々の確率分布  $p(x), p(y)$  に分解できる.

$$\begin{aligned} p(x, y) &= p(x | y)p(y) = p(x)p(y) \quad (\because p(x | y) = p(x)) \\ &= p(y | x)p(x) = p(x)p(y) \quad (\because p(y | x) = p(y)) \end{aligned}$$

- $p(x, y) = p(x)p(y)$  であれば,  $x, y$  は独立である.

# ベイズの定理 (Bayes' Theorem)

- 確率の乗法定理から、**ベイズの定理**が得られる:

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x} | \mathbf{y})p(\mathbf{y}) \quad \longrightarrow \quad p(\mathbf{x} | \mathbf{y}) = \frac{p(\mathbf{y} | \mathbf{x})p(\mathbf{x})}{p(\mathbf{y})}$$

- 分母は周辺化としてかける.

$$\begin{aligned} p(\mathbf{y}) &= p(\mathbf{y}) \underbrace{\int p(\mathbf{x} | \mathbf{y}) d\mathbf{x}}_{=1} = \int p(\mathbf{x} | \mathbf{y})p(\mathbf{y}) d\mathbf{x} \\ &= \int p(\mathbf{x}, \mathbf{y}) d\mathbf{x} = \int p(\mathbf{y} | \mathbf{x})p(\mathbf{x}) d\mathbf{x} \end{aligned}$$

- ベイズの定理は、次のようになる.

$$p(\mathbf{x} | \mathbf{y}) = \frac{p(\mathbf{y} | \mathbf{x})p(\mathbf{x})}{p(\mathbf{y})} = \frac{p(\mathbf{y} | \mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y} | \mathbf{x})p(\mathbf{x}) d\mathbf{x}}$$

# ベイズの定理 (Bayes' Theorem)

## ベイズの定理

$$p(\mathbf{x} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})}{p(\mathbf{y})} = \frac{p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x}) d\mathbf{x}}$$

分母は,  $p(\mathbf{x} \mid \mathbf{y})$  が確率分布になるための正規化 ( $\mathbf{x}$  による積分が 1).

# ベイズの定理 (Bayes' Theorem)

- ベイズの定理:

$$p(\mathbf{x} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})}{p(\mathbf{y})} = \frac{p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})}{\int p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x}) d\mathbf{x}}$$

- センサデータ  $\mathbf{y}$  を手掛かりに, 変数  $\mathbf{x}$  を推定したい.

- 例えば,  $\mathbf{y}$  は GPS のデータ,  $\mathbf{x}$  は GPS の位置.

1  $\mathbf{x}$  に関する仮説を, **事前分布** (Prior)  $p(\mathbf{x})$  として決める.

2 センサのモデルを,  $p(\mathbf{y} \mid \mathbf{x})$  として決める.

- 変数  $\mathbf{x}$  のもとで, どのようなセンサデータ  $\mathbf{y}$  が得られるのか?

3 新たなセンサデータ  $\mathbf{y}$  を得たら,  $p(\mathbf{y} \mid \mathbf{x})p(\mathbf{x})$  を計算し, 正規化する.

4  $\mathbf{y}$  を取り込んだ,  $\mathbf{x}$  の**事後分布** (Posterior)  $p(\mathbf{x} \mid \mathbf{y})$  が得られる.

# ベイズの定理 (Bayes' Theorem)

- 2 つの変数  $y_1, y_2$  から, 変数  $x$  の事後分布  $p(x | y_1, y_2)$  を推定したい.

$$p(x | y_1, y_2) = \frac{p(y_1, y_2 | x)p(x)}{p(y_1, y_2)} \quad (\because \text{ベイズの定理})$$

- $x$  のもとで  $y_1, y_2$  が互いに独立なら, 以下が成り立つ:

$$p(y_1, y_2 | x) = p(y_1 | x)p(y_2 | x) = \frac{p(x | y_1)p(y_1)}{p(x)} \frac{p(x | y_2)p(y_2)}{p(x)}$$

- 上記を代入すれば, 次が得られる.

$$p(x | y_1, y_2) = \eta p(x | y_1)p(x | y_2)$$

- $\eta = \frac{p(y_1)p(y_2)}{p(y_1, y_2)p(x)}$  は正規化項である.

# モーメント, 平均, 分散, 歪度, 尖度

- 確率分布  $p(x)$  の形状ではなく, モーメントだけを扱うことは多々ある.
- $\mathbb{E}[f(x)]$  を, 関数  $f(x)$  の, 確率分布  $p(x)$  のもとでの**期待値**とする.

$$\mathbb{E}[f(x)] = \int f(x)p(x) dx$$

- 1 次モーメント: **平均**  $\mu = \mathbb{E}[x]$  (Mean)
- 2 次モーメント: **分散**  $\sigma^2 = \mathbb{E}[(x - \mu)^2]$  (Variance)
- 3 次モーメント: **歪度**  $\mathbb{E}[(x - \mu)^3]$  (Skewness; わいど)
- 4 次モーメント: **尖度**  $\mathbb{E}[(x - \mu)^4]$  (Kurtosis; せんど)

$$\mu = \mathbb{E}[x] = \int xp(x) dx$$

$$\sigma^2 = \mathbb{E}[(x - \mu)^2] = \int (x - \mu)^2 p(x) dx$$



# モーメント, 平均, 分散 (多変数の場合)

- 行列関数  $\mathbf{F}(\mathbf{x})$  の, 確率分布  $p(\mathbf{x})$  のもとでの期待値:

$$\mathbb{E}[\mathbf{F}(\mathbf{x})] = \int \mathbf{F}(\mathbf{x})p(\mathbf{x}) d\mathbf{x}$$

- $\mathbb{E}[\mathbf{F}(\mathbf{x})]$  の  $(i, j)$  成分は,  $\mathbf{F}$  の  $(i, j)$  成分  $f_{ij}$  を用いて,

$$(\mathbb{E}[\mathbf{F}(\mathbf{x})])_{ij} = \mathbb{E}[f_{ij}(\mathbf{x})] = \int f_{ij}(\mathbf{x})p(\mathbf{x}) d\mathbf{x}$$

- 平均  $\boldsymbol{\mu}$  と分散  $\boldsymbol{\Sigma}$  は, 次のようにかける.

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}] = \int \mathbf{x}p(\mathbf{x}) d\mathbf{x}$$

$$\boldsymbol{\Sigma} = \mathbb{E}\left[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top\right] = \int (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top p(\mathbf{x}) d\mathbf{x}$$

# モーメント, 平均, 分散 (多変数の場合)

- 確率分布  $p(\mathbf{x})$  の分散  $\Sigma$  について, 次が成り立つ.

$$\Sigma = \mathbb{E} [\mathbf{x}\mathbf{x}^\top] - \mathbb{E} [\mathbf{x}] \mathbb{E} [\mathbf{x}]^\top = \mathbb{E} [\mathbf{x}\mathbf{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top$$

- スカラの場合は, 次のようになる.

$$\sigma^2 = \mathbb{E} [x^2] - (\mathbb{E} [x])^2 = \mathbb{E} [x^2] - \mu^2$$

- 以下のように示せる.

$$\begin{aligned}\Sigma &= \mathbb{E} [(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top] \\ &= \mathbb{E} [\mathbf{x}\mathbf{x}^\top] - \mathbb{E} [\mathbf{x}\boldsymbol{\mu}^\top] - \mathbb{E} [\boldsymbol{\mu}\mathbf{x}^\top] + \mathbb{E} [\boldsymbol{\mu}\boldsymbol{\mu}^\top] \\ &= \mathbb{E} [\mathbf{x}\mathbf{x}^\top] - \mathbb{E} [\mathbf{x}] \boldsymbol{\mu}^\top - \boldsymbol{\mu} \mathbb{E} [\mathbf{x}]^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\ &= \mathbb{E} [\mathbf{x}\mathbf{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top - \boldsymbol{\mu}\boldsymbol{\mu}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top\end{aligned}$$

# 独立 (Independent), 無相関 (Uncorrelated)

- 以下が成り立つとき,  $\mathbf{x}, \mathbf{y}$  は**独立**である:

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y})$$

- 以下が成り立つとき,  $\mathbf{x}, \mathbf{y}$  は**無相関**である:

$$\mathbb{E} [\mathbf{xy}^\top] = \mathbb{E} [\mathbf{x}] \mathbb{E} [\mathbf{y}]^\top$$

- 独立  $\Rightarrow$  無相関は成り立つが, 無相関  $\Rightarrow$  独立は**成り立たない**.
- 独立  $\Rightarrow$  無相関は, 次のように示せる.

$$\begin{aligned}\mathbb{E} [\mathbf{xy}^\top] &= \iint \mathbf{xy}^\top p(\mathbf{x}, \mathbf{y}) \, d\mathbf{x} \, d\mathbf{y} = \iint \mathbf{xy}^\top p(\mathbf{x})p(\mathbf{y}) \, d\mathbf{x} \, d\mathbf{y} \quad (\because \text{独立}) \\ &= \int \mathbf{x}p(\mathbf{x}) \, d\mathbf{x} \int \mathbf{y}^\top p(\mathbf{y}) \, d\mathbf{y} = \mathbb{E} [\mathbf{x}] \mathbb{E} [\mathbf{y}]^\top\end{aligned}$$

# 共分散 (Covariance)

- $\mathbf{x}, \mathbf{y}$  について, **共分散**は次のようにかける.

$$\mathbb{E} \left[ (\mathbf{x} - \mathbb{E}[\mathbf{x}]) (\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top \right] = \mathbb{E} [\mathbf{x} \mathbf{y}^\top] - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top$$

- 左辺を展開すれば, 次のように示せる.

$$\begin{aligned} & \mathbb{E} \left[ (\mathbf{x} - \mathbb{E}[\mathbf{x}]) (\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top \right] \\ &= \mathbb{E} [\mathbf{x} \mathbf{y}^\top] - \mathbb{E} [\mathbf{x} \mathbb{E}[\mathbf{y}]^\top] - \mathbb{E} [\mathbb{E}[\mathbf{x}] \mathbf{y}^\top] + \mathbb{E} [\mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top] \\ &= \mathbb{E} [\mathbf{x} \mathbf{y}^\top] - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top - \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top + \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top \end{aligned}$$

- $\mathbf{x}, \mathbf{y}$  が無相関 ( $\mathbb{E} [\mathbf{x} \mathbf{y}^\top] = \mathbb{E}[\mathbf{x}] \mathbb{E}[\mathbf{y}]^\top$ ) であれば, 共分散は 0 である.
- 独立  $\Rightarrow$  無相関であるから, 独立であれば, 共分散は 0 である.

# イェンセンの不等式 (Jensen's Inequality)

- 上に凸な関数  $f(\mathbf{x})$  を考える.
- $p(\mathbf{x})$  を,  $\int p(\mathbf{x}) d\mathbf{x} = 1$  をみたす関数とする.
- $f(\mathbf{x}), p(\mathbf{x})$  について, **イェンセンの不等式**が成り立つ:

$$\int f(\mathbf{x})p(\mathbf{x}) d\mathbf{x} \geq f\left(\int \mathbf{x}p(\mathbf{x}) d\mathbf{x}\right)$$

- $p(\mathbf{x})$  を確率分布とすれば, 期待値  $\mathbb{E}[\cdot]$  を用いて, 次のようにかける:

$$\mathbb{E}[f(\mathbf{x})] \geq f(\mathbb{E}[\mathbf{x}])$$


- $f(\mathbf{x})$  が下に凸であれば, 次が成り立つ (不等号が逆になる):

$$\int f(\mathbf{x})p(\mathbf{x}) d\mathbf{x} \leq f\left(\int \mathbf{x}p(\mathbf{x}) d\mathbf{x}\right)$$

$$\mathbb{E}[f(\mathbf{x})] \leq f(\mathbb{E}[\mathbf{x}])$$

# イェンセンの不等式 (Jensen's Inequality)

- **下に凸**であれば, 任意の 2 点を結ぶ直線が, 上側にある (**凸関数**, 左).
  - $x^2$ ,  $x \ln x$ ,  $\frac{1}{x}$  ( $x > 0$ ),  $\tan x$  ( $0 < x < \frac{\pi}{2}$ ) など
- **上に凸**であれば, 任意の 2 点を結ぶ直線が, 下側にある (**凹関数**, 右).
  - $\ln x$ ,  $\tan x$  ( $-\frac{\pi}{2} < x < 0$ ) など



# エントロピー (Entropy)

- 確率分布  $p(\mathbf{x})$  について, 次の量  $H[\mathbf{x}]$  を考える.

$$H[\mathbf{x}] = -\mathbb{E}[\ln p(\mathbf{x})] = -\int p(\mathbf{x}) \ln p(\mathbf{x}) d\mathbf{x}$$

- $H[\mathbf{x}]$  を, **エントロピー**, **シャノン情報量**, **平均情報量**とよぶ.
- 直感的には,  $\mathbf{x}$  を, どのくらい予測しづらいのかを表す.
  - $\mathbf{x}$  が離散変数であれば, 一様分布のときにエントロピーが最大である.
  - $\mathbf{x}$  が連続変数であれば, 正規分布 (ガウス分布) のときに最大.
  - この証明には, 変分計算が必要である.

# 条件付きエントロピー (Conditional Entropy)

- 同時分布  $p(\mathbf{x}, \mathbf{y})$  のエントロピー  $H[\mathbf{x}, \mathbf{y}]$  を考える.

$$H[\mathbf{x}, \mathbf{y}] = -\mathbb{E}[\ln p(\mathbf{x}, \mathbf{y})] = -\iint p(\mathbf{x}, \mathbf{y}) \ln p(\mathbf{x}, \mathbf{y}) \, d\mathbf{x} \, d\mathbf{y}$$

- $p(\mathbf{x}, \mathbf{y}) = p(\mathbf{y} | \mathbf{x})p(\mathbf{x})$  のように分解できるので, 代入すれば

$$\begin{aligned} H[\mathbf{x}, \mathbf{y}] &= -\iint p(\mathbf{y} | \mathbf{x})p(\mathbf{x}) (\ln p(\mathbf{y} | \mathbf{x}) + \ln p(\mathbf{x})) \, d\mathbf{x} \, d\mathbf{y} \\ &= -\iint p(\mathbf{x}, \mathbf{y}) \ln p(\mathbf{y} | \mathbf{x}) \, d\mathbf{x} \, d\mathbf{y} \\ &\quad - \int p(\mathbf{x}) \ln p(\mathbf{x}) \, d\mathbf{x} \underbrace{\int p(\mathbf{y} | \mathbf{x}) \, d\mathbf{y}}_{=1} \\ &= H[\mathbf{y} | \mathbf{x}] + H[\mathbf{x}] \end{aligned}$$



# 条件付きエントロピー (Conditional Entropy)

- 条件付き確率分布  $p(y | x)$  について,  $H[y | x]$  を次のように定める.

$$H[y | x] = -\mathbb{E}[\ln p(y | x)] = -\iint p(x, y) \ln p(y | x) dx dy$$

- $H[y | x]$  を, **条件付きエントロピー**とよぶ.
- 次が成り立つ:

$$H[x, y] = H[y | x] + H[x] = H[x | y] + H[y]$$

- $H[x]$ :  $x$  の予測しづらさ
- $H[x, y]$ :  $x$  と  $y$  の予測しづらさ
- $H[y | x]$ :  $x$  が既知であるときの,  $y$  の予測しづらさ

# カルバック-ライブラーダイバージェンス (Kullback-Leibler Divergence)

- 2つの確率分布  $p(\mathbf{x}), q(\mathbf{x})$  があるとき, 次の量  $\text{KL}(p \parallel q)$  を考える.

$$\text{KL}(p \parallel q) = -\mathbb{E} \left[ \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} \right] = - \int p(\mathbf{x}) \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x}$$

- $\text{KL}(p \parallel q)$  を, **カルバック-ライブラーダイバージェンス**とよぶ.
- 長いので, **KL ダイバージェンス**ともよぶ.
- 確率分布  $p(\mathbf{x})$  と  $q(\mathbf{x})$  との距離のような概念である.
- $\text{KL}(p \parallel q) \neq \text{KL}(q \parallel p)$  であるから, 厳密な距離ではない.

# カルバック-ライブラーダイバージェンス (Kullback-Leibler Divergence)

- カルバック-ライブラーダイバージェンス:

$$\text{KL}(p \parallel q) = -\mathbb{E} \left[ \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} \right] = - \int p(\mathbf{x}) \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x}$$

- $\ln$  は下に凸だから、イェンセンの不等式より ( $\mathbb{E}[f(x)] \leq f(\mathbb{E}[x])$ )

$$\begin{aligned} \text{KL}(p \parallel q) &= -\mathbb{E} \left[ \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} \right] \geq -\ln \mathbb{E} \left[ \frac{q(\mathbf{x})}{p(\mathbf{x})} \right] \\ &= -\ln \int p(\mathbf{x}) \frac{q(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x} = -\ln \int q(\mathbf{x}) d\mathbf{x} = -\ln 1 = 0 \end{aligned}$$

- 以上より,  $\text{KL}(p \parallel q) \geq 0$ .
- $\forall \mathbf{x} \ p(\mathbf{x}) = q(\mathbf{x})$  のときのみ 0.

# 相互情報量 (Mutual Information)

- 確率変数  $x, y$  について, 次の量  $I(x, y)$  を考える.

$$I(x, y) = \mathbb{E} \left[ \ln \frac{p(x, y)}{p(x)p(y)} \right] = \iint p(x, y) \ln \frac{p(x, y)}{p(x)p(y)} dx dy$$

- $I(x, y)$  を, **相互情報量**とよぶ.
- $x(y)$  を得たとき,  $y(x)$  についての情報がどのくらい増えるか.
- $x, y$  が独立であれば ( $p(x, y) = p(x)p(y)$ ),  $I(x, y) = 0$ .

$$I(x, y) = \iint p(x, y) \ln \frac{p(x)p(y)}{p(x)p(y)} dx dy = \iint p(x, y) \ln 1 dx dy = 0$$

- $x, y$  が独立であれば,  $x(y)$  のことが分かってても,  $y(x)$  については何の情報ももたらさない.

# 相互情報量 (Mutual Information)

- 相互情報量  $I(\mathbf{x}, \mathbf{y})$ :

$$I(\mathbf{x}, \mathbf{y}) = \mathbb{E} \left[ \ln \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{x})p(\mathbf{y})} \right] = \iint p(\mathbf{x}, \mathbf{y}) \ln \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{x})p(\mathbf{y})} d\mathbf{x} d\mathbf{y}$$

- エントロピー  $H[\mathbf{x}]$ ,  $H[\mathbf{y}]$ ,  $H[\mathbf{x}, \mathbf{y}]$  を使って, 次のようにかける.

$$I(\mathbf{x}, \mathbf{y}) = H[\mathbf{x}] + H[\mathbf{y}] - H[\mathbf{x}, \mathbf{y}]$$

- $H[\mathbf{x}, \mathbf{y}] = H[\mathbf{y} | \mathbf{x}] + H[\mathbf{x}] = H[\mathbf{x} | \mathbf{y}] + H[\mathbf{y}]$  であるから,

$$I(\mathbf{x}, \mathbf{y}) = H[\mathbf{y}] - H[\mathbf{y} | \mathbf{x}] = H[\mathbf{x}] - H[\mathbf{x} | \mathbf{y}]$$

- $H[\mathbf{y}]$ :  $\mathbf{y}$  の予測しづらさ
- $H[\mathbf{y} | \mathbf{x}]$ :  $\mathbf{x}$  が既知であるときの,  $\mathbf{y}$  の予測しづらさ
- $I(\mathbf{x}, \mathbf{y})$ :  $\mathbf{x}$  が分かったとき,  $\mathbf{y}$  がどのくらい予測しやすくなるか

# 相互情報量 (Mutual Information)

- 相互情報量  $I(\mathbf{x}, \mathbf{y})$ :

$$I(\mathbf{x}, \mathbf{y}) = \mathbb{E} \left[ \ln \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{x})p(\mathbf{y})} \right] = \iint p(\mathbf{x}, \mathbf{y}) \ln \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{x})p(\mathbf{y})} d\mathbf{x} d\mathbf{y}$$

- カルバック-ライブラーダイバージェンスを用いると,

$$I(\mathbf{x}, \mathbf{y}) = -\mathbb{E} \left[ \ln \frac{p(\mathbf{x})p(\mathbf{y})}{p(\mathbf{x}, \mathbf{y})} \right] = \text{KL}(p(\mathbf{x}, \mathbf{y}) \parallel p(\mathbf{x})p(\mathbf{y}))$$

- KL ダイバージェンスの性質 ( $\geq 0$ ) から,  $I(\mathbf{x}, \mathbf{y}) \geq 0$ .
- $\forall \mathbf{x}, \mathbf{y} \ p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x})p(\mathbf{y})$  のとき (独立であるとき) に限って 0.
- 確率変数  $\mathbf{x}, \mathbf{y}$  が, 独立に近いかどうかを表している.

# 不偏推定量 (Unbiased Estimate)

- パラメータ  $\theta$  をもつ  $\mathbf{x}$  の確率分布  $p(\mathbf{x} \mid \theta)$  を考える.
- この確率分布から, 観測データが得られたとする.

$$\mathbf{x}_{\text{meas}} \leftarrow p(\mathbf{x} \mid \theta)$$

- 観測データ  $\mathbf{x}_{\text{meas}}$  を基に, パラメータ  $\theta$  を推定したい.
- パラメータ  $\theta$  の推定量  $\hat{\theta}$  が, **不偏推定量**であるとき, 以下が成り立つ:

$$\mathbb{E}[\hat{\theta}] = \theta \quad \longrightarrow \quad \mathbb{E}[\hat{\theta} - \theta] = 0$$

- 推定量の期待値  $\mathbb{E}[\hat{\theta}]$  が, パラメータ  $\theta$  に一致する (偏りが無い).

# 不偏推定量 (Unbiased Estimate)

- 例えば, 平均  $\mu$  と共分散  $\Sigma$  をもつ  $\mathbf{x}$  の確率分布  $p(\mathbf{x} \mid \mu, \Sigma)$  から,  $N$  個の観測データが得られたとする:

$$\{\mathbf{x}_{1,\text{meas}}, \dots, \mathbf{x}_{N,\text{meas}}\} \leftarrow p(\mathbf{x} \mid \mu, \Sigma)$$
$$\mathbb{E}[\mathbf{x}_{\text{meas}}] = \mu, \quad \mathbb{E}\left[(\mathbf{x}_{\text{meas}} - \mu)(\mathbf{x}_{\text{meas}} - \mu)^\top\right] = \Sigma$$

- 観測データは, **互いに独立**であるとする.
- 観測データ  $\{\mathbf{x}_{i,\text{meas}}\}$  を基に, 分布の平均  $\mu$  と共分散  $\Sigma$  を推定したい.



# 不偏推定量 (Unbiased Estimate)

- 平均  $\mu$  と共分散  $\Sigma$  をもつ  $\mathbf{x}$  の確率分布  $p(\mathbf{x} \mid \mu, \Sigma)$  から,  $N$  個の観測データが得られたとする:

$$\{\mathbf{x}_{1,\text{meas}}, \dots, \mathbf{x}_{N,\text{meas}}\} \leftarrow p(\mathbf{x} \mid \mu, \Sigma)$$

- 観測データ  $\{\mathbf{x}_{i,\text{meas}}\}$  を基に, 分布の平均  $\mu$  と共分散  $\Sigma$  を推定したい.
- 平均と共分散の**不偏推定量**は, 次のようになる:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_{i,\text{meas}}, \quad \hat{\Sigma} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \hat{\mu})(\mathbf{x}_{i,\text{meas}} - \hat{\mu})^\top$$

- 分散については, 分母が  $N$  の代わりに  $N-1$  となることに注意.
- $\hat{\mu}$  は, **標本平均**という.
- $\hat{\Sigma}$  は, **不偏分散**という (分母が  $N$  のときは, **標本分散**).

# 不偏推定量 (Unbiased Estimate)

- 不偏分散は, 分母が  $N$  の代わりに  $N - 1$  になる (少し大きく補正):

$$\hat{\Sigma} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \hat{\boldsymbol{\mu}}) (\mathbf{x}_{i,\text{meas}} - \hat{\boldsymbol{\mu}})^\top$$

- 分散の計算に, 真の平均  $\boldsymbol{\mu}$  ではなく, **観測データから計算された** 標本平均  $\hat{\boldsymbol{\mu}}$  を使っているから.
  - 観測データ  $\mathbf{x}_{i,\text{meas}}$  と, 標本平均  $\hat{\boldsymbol{\mu}}$  の間には相関がある.
  - 差分  $\mathbf{x}_{i,\text{meas}} - \hat{\boldsymbol{\mu}}$  は, 真の平均から計算された, 本当の差分  $\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu}$  よりは小さくなりがちである.
- $\hat{\boldsymbol{\mu}}$  が平均の不偏推定量であることは, 次のように分かる:

$$\mathbb{E}[\hat{\boldsymbol{\mu}}] = \mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N \mathbf{x}_{i,\text{meas}}\right] = \frac{1}{N} \sum_{i=1}^N \underbrace{\mathbb{E}[\mathbf{x}_{i,\text{meas}}]}_{=\boldsymbol{\mu}} = \frac{1}{N} \sum_{i=1}^N \boldsymbol{\mu} = \boldsymbol{\mu}$$

# 不偏推定量 (Unbiased Estimate)

- また,  $\Sigma = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top$  を用いて,

$$\begin{aligned}\mathbb{E}[\hat{\boldsymbol{\mu}}\hat{\boldsymbol{\mu}}^\top] &= \mathbb{E}\left[\left(\frac{1}{N}\sum_{i=1}^N \mathbf{x}_{i,\text{meas}}\right)\left(\frac{1}{N}\sum_{j=1}^N \mathbf{x}_{j,\text{meas}}\right)^\top\right] \\&= \frac{1}{N^2}\sum_{i=1}^N\sum_{j=1}^N \mathbb{E}[\mathbf{x}_{i,\text{meas}}\mathbf{x}_{j,\text{meas}}^\top] \\&= \frac{1}{N^2}\sum_{i=1}^N \mathbb{E}[\mathbf{x}_{i,\text{meas}}\mathbf{x}_{i,\text{meas}}^\top] + \frac{1}{N^2}\sum_{i \neq j} \mathbb{E}[\mathbf{x}_{i,\text{meas}}\mathbf{x}_{j,\text{meas}}^\top] \\&= \frac{1}{N^2} \cdot N(\Sigma + \boldsymbol{\mu}\boldsymbol{\mu}^\top) + \frac{1}{N^2} \cdot N(N-1)\boldsymbol{\mu}\boldsymbol{\mu}^\top = \frac{1}{N}\Sigma + \boldsymbol{\mu}\boldsymbol{\mu}^\top\end{aligned}$$

- 観測データは互いに独立だから, 無相関であって,  $i \neq j$  のとき

$$\mathbb{E}[\mathbf{x}_{i,\text{meas}}\mathbf{x}_{j,\text{meas}}^\top] = \mathbb{E}[\mathbf{x}_{i,\text{meas}}]\mathbb{E}[\mathbf{x}_{j,\text{meas}}]^\top = \boldsymbol{\mu}\boldsymbol{\mu}^\top$$

# 不偏推定量 (Unbiased Estimate)

- $\hat{\mu}$  の分散  $\mathbb{E} \left[ (\hat{\mu} - \mathbb{E} [\hat{\mu}]) (\hat{\mu} - \mathbb{E} [\hat{\mu}])^\top \right]$  は,

$$\begin{aligned} \mathbb{E} \left[ (\hat{\mu} - \mathbb{E} [\hat{\mu}]) (\hat{\mu} - \mathbb{E} [\hat{\mu}])^\top \right] &= \mathbb{E} \left[ (\hat{\mu} - \mu) (\hat{\mu} - \mu)^\top \right] \\ &= \mathbb{E} [\hat{\mu} \hat{\mu}^\top] - \mathbb{E} [\hat{\mu}] \mu^\top - \mu \mathbb{E} [\hat{\mu}]^\top + \mu \mu^\top \\ &= \frac{1}{N} \Sigma + \mu \mu^\top - \mu \mu^\top - \mu \mu^\top + \mu \mu^\top \\ &= \frac{1}{N} \Sigma \end{aligned}$$

- $\mathbb{E} [\hat{\mu} \hat{\mu}^\top] = \frac{1}{N} \Sigma + \mu \mu^\top$ ,  $\mathbb{E} [\hat{\mu}] = \mu$  を用いた.
- 観測データが増えれば ( $N \rightarrow \infty$ ), 上記の分散は 0 に近づく.
- 言い換えると, 平均の不偏推定量  $\hat{\mu}$  は,  $\mathbb{E} [\hat{\mu}] = \mu$  に近づいてゆく.

# 不偏推定量 (Unbiased Estimate)

- $\hat{\Sigma}$  が共分散の不偏推定量であることも, 次のように分かる:

$$\begin{aligned}\mathbb{E}[\hat{\Sigma}] &= \mathbb{E}\left[\frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \hat{\boldsymbol{\mu}})(\mathbf{x}_{i,\text{meas}} - \hat{\boldsymbol{\mu}})^\top\right] \\&= \mathbb{E}\left[\frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu} + \boldsymbol{\mu} - \hat{\boldsymbol{\mu}})(\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu} + \boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top\right] \\&= \frac{1}{N-1} \left( \sum_{i=1}^N \mathbb{E}\left[(\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})(\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})^\top\right] \right. \\&\quad \left. + \mathbb{E}\left[\sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})(\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top\right] \right. \\&\quad \left. + \mathbb{E}\left[\sum_{i=1}^N (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})(\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})^\top\right] + \sum_{i=1}^N \mathbb{E}\left[(\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})(\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top\right] \right)\end{aligned}$$

# 不偏推定量 (Unbiased Estimate)

- 各項は,

$$\mathbb{E} \left[ (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu}) (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})^\top \right] = \boldsymbol{\Sigma}$$

$$\mathbb{E} \left[ (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}}) (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top \right] = \frac{1}{N} \boldsymbol{\Sigma}$$

$$\mathbb{E} \left[ \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu}) (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top \right] = \mathbb{E} \left[ N (\hat{\boldsymbol{\mu}} - \boldsymbol{\mu}) (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}})^\top \right] = -\boldsymbol{\Sigma}$$

$$\mathbb{E} \left[ \sum_{i=1}^N (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}}) (\mathbf{x}_{i,\text{meas}} - \boldsymbol{\mu})^\top \right] = \mathbb{E} \left[ N (\boldsymbol{\mu} - \hat{\boldsymbol{\mu}}) (\hat{\boldsymbol{\mu}} - \boldsymbol{\mu})^\top \right] = -\boldsymbol{\Sigma}$$

- $\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_{i,\text{meas}}$  であるから,  $\sum_{i=1}^N \mathbf{x}_{i,\text{meas}} = N \hat{\boldsymbol{\mu}}$ .

- これらを,  $\mathbb{E} \left[ \hat{\boldsymbol{\Sigma}} \right]$  の式に代入する.

# 不偏推定量 (Unbiased Estimate)

- $\mathbb{E} [\hat{\Sigma}]$  を計算すると,

$$\begin{aligned}\mathbb{E} [\hat{\Sigma}] &= \frac{1}{N-1} \left( \sum_{i=1}^N \Sigma - \Sigma - \Sigma + \sum_{i=1}^N \frac{1}{N} \Sigma \right) \\ &= \frac{1}{N-1} (N\Sigma - \Sigma - \Sigma + \Sigma) = \frac{1}{N-1} (N-1)\Sigma = \Sigma\end{aligned}$$

- 以上より, 平均と共分散の**不偏推定量**は, 次のようになる:

$$\begin{aligned}\hat{\mu} &= \frac{1}{N} \sum_{i=1}^N \mathbf{x}_{i,\text{meas}}, & \hat{\Sigma} &= \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_{i,\text{meas}} - \hat{\mu})(\mathbf{x}_{i,\text{meas}} - \hat{\mu})^\top \\ \mathbb{E} [\hat{\mu}] &= \mu, & \mathbb{E} [\hat{\Sigma}] &= \Sigma \\ \mathbb{E} [\hat{\mu}\hat{\mu}^\top] &= \frac{1}{N}\Sigma + \mu\mu^\top, & \mathbb{E} [(\hat{\mu} - \mu)(\hat{\mu} - \mu)^\top] &= \frac{1}{N}\Sigma\end{aligned}$$

# クラメール・ラオの下限 (Cramér–Rao Lower Bound)

- パラメータ  $\theta$  をもつ  $\mathbf{x}$  の確率分布  $p(\mathbf{x} | \theta)$  を考える.
- この確率分布から, 観測データが得られたとする.

$$\mathbf{x}_{\text{meas}} \leftarrow p(\mathbf{x} | \theta)$$

- 観測データ  $\mathbf{x}_{\text{meas}}$  を基に, パラメータ  $\theta$  の不偏推定量  $\hat{\theta}$  を計算する.

$$\mathbb{E} [\hat{\theta} - \theta] = 0$$

- 不偏推定量  $\hat{\theta}$  の分散について, 以下が成り立つ:

$$\mathbb{E} \left[ (\hat{\theta} - \theta) (\hat{\theta} - \theta)^{\top} \right] \geq \mathbf{I}^{-1}(\mathbf{x} | \theta)$$

- これを, **クラメール・ラオの下限**という.



# クラメル・ラオの下限 (Cramér–Rao Lower Bound)

- 確率分布  $p(\mathbf{x} \mid \theta)$  のパラメータ  $\theta$  の不偏推定量  $\hat{\theta}$  について,

$$\mathbb{E} \left[ \left( \hat{\theta} - \theta \right) \left( \hat{\theta} - \theta \right)^{\top} \right] \geq \mathbf{I}^{-1}(\mathbf{x} \mid \theta)$$

- $\mathbf{I}(\mathbf{x} \mid \theta)$  は, **フィッシャー情報行列**とよぶ.

$$\mathbf{I}(\mathbf{x} \mid \theta) = \mathbb{E} \left[ \left( \frac{\partial \ln p(\mathbf{x} \mid \theta)}{\partial \theta} \right)^{\top} \left( \frac{\partial \ln p(\mathbf{x} \mid \theta)}{\partial \theta} \right) \right]$$

- 不等号  $\mathbf{A} \geq \mathbf{B}$  は, 行列  $\mathbf{A} - \mathbf{B}$  が半正定値になることを意味する.

$$\forall \mathbf{x} \neq \mathbf{0} \quad \mathbf{x}^{\top} (\mathbf{A} - \mathbf{B}) \mathbf{x} \geq 0 \quad \longrightarrow \quad \mathbf{A} - \mathbf{B} \geq 0$$

- 観測データを使ってパラメータを推定するとき, その精度には限度がある.

# 目次

- ① 概要
- ② 確率分布
- ③ **ガウス積分**

# 微分のレイアウト (再掲)

- 以下の2つのレイアウトに大別される ( $x, y$  を縦ベクトルとする).
- **分子レイアウト** (Numerator Layout)
  - $\frac{\partial y}{\partial x}$  は, 縦ベクトル,  $\frac{\partial y}{\partial \mathbf{x}}$  は, 横ベクトル
- **分母レイアウト** (Denominator Layout)
  - $\frac{\partial y}{\partial x}$  は, 横ベクトル,  $\frac{\partial y}{\partial \mathbf{x}}$  は, 縦ベクトル

# スカラによる微分 (再掲)

分子レイアウト

$$\frac{\partial y}{\partial x}$$

$$\frac{\partial \mathbf{y}}{\partial x} = \begin{pmatrix} \frac{\partial y_1}{\partial x} \\ \vdots \\ \frac{\partial y_m}{\partial x} \end{pmatrix}$$

分母レイアウト

$$\frac{\partial y}{\partial x}$$

$$\frac{\partial \mathbf{y}}{\partial x} = \begin{pmatrix} \frac{\partial y_1}{\partial x} & \cdots & \frac{\partial y_m}{\partial x} \end{pmatrix} \equiv \frac{\partial \mathbf{y}^\top}{\partial x}$$

$$\frac{\partial \mathbf{Y}}{\partial x} = \begin{pmatrix} \frac{\partial y_{11}}{\partial x} & \cdots & \frac{\partial y_{1n}}{\partial x} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_{m1}}{\partial x} & \cdots & \frac{\partial y_{mn}}{\partial x} \end{pmatrix}$$

まれ

# ベクトルによる微分 (再掲)

## 分子レイアウト

$$\frac{\partial y}{\partial \mathbf{x}} = \left( \frac{\partial y}{\partial x_1} \quad \cdots \quad \frac{\partial y}{\partial x_n} \right) \equiv \frac{\partial y}{\partial \mathbf{x}^\top}$$

## 分母レイアウト

$$\frac{\partial y}{\partial \mathbf{x}} = \begin{pmatrix} \frac{\partial y}{\partial x_1} \\ \vdots \\ \frac{\partial y}{\partial x_n} \end{pmatrix}$$

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

$$\equiv \frac{\partial \mathbf{y}}{\partial \mathbf{x}^\top}$$

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

$$\equiv \frac{\partial \mathbf{y}^\top}{\partial \mathbf{x}}$$

# 行列による微分 (再掲)

分子レイアウト

$$\frac{\partial y}{\partial \mathbf{X}} = \begin{pmatrix} \frac{\partial y}{\partial x_{11}} & \cdots & \frac{\partial y}{\partial x_{m1}} \\ \vdots & \ddots & \vdots \\ \frac{\partial y}{\partial x_{1n}} & \cdots & \frac{\partial y}{\partial x_{mn}} \end{pmatrix}$$
$$\equiv \frac{\partial y}{\partial \mathbf{X}^\top}$$

分母レイアウト

$$\frac{\partial y}{\partial \mathbf{X}} = \begin{pmatrix} \frac{\partial y}{\partial x_{11}} & \cdots & \frac{\partial y}{\partial x_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial y}{\partial x_{m1}} & \cdots & \frac{\partial y}{\partial x_{mn}} \end{pmatrix}$$
$$\equiv \frac{\partial y}{\partial \mathbf{X}}$$

# ヤコビ行列, ヤコビアン (Jacobi Matrix, Jacobian)

- $n, m$  次変数  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ ,  $\mathbf{y} = (y_1, y_2, \dots, y_m)^\top$  を考える.
- $\frac{\partial y_i}{\partial x_j}$  を  $(i, j)$  成分とした  $m \times n$  行列  $\mathbf{J}$  を, ヤコビ行列という.

$$\mathbf{J} = \frac{\partial(y_1, y_2, \dots, y_m)}{\partial(x_1, x_2, \dots, x_n)} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_m}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}$$

- 分子レイアウトにおける  $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \equiv \frac{\partial \mathbf{y}}{\partial \mathbf{x}^\top}$  と同じ.
- ヤコビ行列の行列式  $\det \mathbf{J}$  を, ヤコビアンとよぶ.

# 積分の変数変換

- $n, m$  次元変数  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$ ,  $\mathbf{y} = (y_1, y_2, \dots, y_m)^\top$  を考える.
- 関数  $f(\mathbf{y})$  があり, 次の積分を行いたいとする:

$$\int f(\mathbf{y}) \, d\mathbf{y}$$

- $\mathbf{y} = \mathbf{g}(\mathbf{x})$ ,  $m \times n$  行列を  $\mathbf{G} = \frac{\partial \mathbf{y}}{\partial \mathbf{x}}$  とおく.
- ヤコビアン  $\det \mathbf{G}$  を使うと, 次のように変数変換できる:

$$\int f(\mathbf{y}) \, d\mathbf{y} \quad \longrightarrow \quad \int f(\mathbf{g}(\mathbf{x})) |\det \mathbf{G}| \, d\mathbf{x}$$

- $d\mathbf{y} = |\det \mathbf{G}| \, d\mathbf{x}$  のように関連付けられる.
- ヤコビアンは, 変数変換による微小な体積  $d\mathbf{x}$ ,  $d\mathbf{y}$  の変化率を表す.



# 積分の変数変換 (スカラーの場合)

- 関数  $f(y)$  があり, 次の計算を行いたいとする:

$$\int f(y) \, dy$$

- $y = g(x)$  とすると, 次のように変数変換できる:

$$\int f(y) \, dy \quad \longrightarrow \quad \int f(g(x)) \frac{dy}{dx} \, dx$$

# 偶関数の積分

- 関数  $f(x)$  が偶関数であれば,  $f(-x) = f(x)$  となる.
- $-a$  から  $a$  までの積分は,

$$\int_{-a}^a f(x) dx = \int_{-a}^0 f(x) dx + \int_0^a f(x) dx$$

- 第一項において  $x = -y$  とすると,  $\frac{dx}{dy} = -1$ , 積分範囲は  $[-a, 0]$  から  $[a, 0]$  になるので,

$$\begin{aligned}\int_{-a}^a f(x) dx &= \int_a^0 \textcolor{red}{f}(-y) \frac{dx}{dy} dy + \int_0^a f(x) dx \\ &= \int_a^0 \textcolor{red}{f}(y)(-1) dy + \int_0^a f(x) dx \\ &= \int_0^a f(y) dy + \int_0^a f(x) dx = 2 \int_0^a f(x) dx\end{aligned}$$

# 奇関数の積分

- 関数  $f(x)$  が奇関数であれば,  $f(-x) = -f(x)$  となる.
- $-a$  から  $a$  までの積分は,

$$\int_{-a}^a f(x) dx = \int_{-a}^0 f(x) dx + \int_0^a f(x) dx$$

- 第一項において  $x = -y$  とすると,  $\frac{dx}{dy} = -1$ , 積分範囲は  $[-a, 0]$  から  $[a, 0]$  になるので,

$$\begin{aligned}\int_{-a}^a f(x) dx &= \int_a^0 \textcolor{red}{f(-y)} \frac{dx}{dy} dy + \int_0^a f(x) dx \\ &= \int_a^0 \textcolor{red}{-f(y)} (-1) dy + \int_0^a f(x) dx \\ &= \int_a^0 (-f(y)) dy + \int_0^a f(x) dx = 0\end{aligned}$$

# 偶関数, 奇関数の積分

## 偶関数, 奇関数の積分

$f(x)$  が偶関数であれば,  $[-a, a]$  の積分は,  $[0, a]$  の積分の 2 倍:

$$\int_{-a}^a f(x) dx = 2 \int_0^a f(x) dx$$

$f(x)$  が奇関数であれば,  $[-a, a]$  の積分は 0:

$$\int_{-a}^a f(x) dx = 0$$

- 以下も成り立つ:
- (奇関数)  $\times$  (奇関数) = (偶関数)
- (奇関数)  $\times$  (偶関数) = (奇関数)
- (偶関数)  $\times$  (偶関数) = (偶関数)

# 偶関数, 奇関数の積分 (多変数関数)

- $n$  次変数  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$  を考える.
- $\mathbf{a} = (a_1, a_2, \dots, a_n)^\top$  として,  $-\mathbf{a}$  から  $\mathbf{a}$  までの  $f(\mathbf{x})$  の積分は,

$$\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x} = \int_{-\mathbf{a}}^{\mathbf{0}} f(\mathbf{x}) d\mathbf{x} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x}$$

- 上式の積分は, 次と同じことである:

$$\begin{aligned} & \int_{-a_1}^{a_1} \int_{-a_2}^{a_2} \cdots \int_{-a_n}^{a_n} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n \\ &= \int_{-a_1}^0 \int_{-a_2}^0 \cdots \int_{-a_n}^0 f(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n \\ & \quad + \int_0^{a_1} \int_0^{a_2} \cdots \int_0^{a_n} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n \end{aligned}$$

# 偶関数, 奇関数の積分 (多変数関数)

- $n$  変数  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$  を考える.
- $\mathbf{a} = (a_1, a_2, \dots, a_n)^\top$  として,  $-\mathbf{a}$  から  $\mathbf{a}$  までの  $f(\mathbf{x})$  の積分は,

$$\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x} = \int_{-\mathbf{a}}^{\mathbf{0}} f(\mathbf{x}) d\mathbf{x} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x}$$

- 第一項において  $\mathbf{x} = -\mathbf{y}$  とすると, ヤコビ行列は  $\frac{\partial \mathbf{x}}{\partial \mathbf{y}} = -\mathbf{I}$ , ヤコビアンは  $\det(-\mathbf{I}) = (-1)^n$ . 積分範囲は  $[-\mathbf{a}, \mathbf{0}]$  から  $[\mathbf{a}, \mathbf{0}]$  になるので,

$$\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathbf{a}}^{\mathbf{0}} f(-\mathbf{y}) (-1)^n d\mathbf{y} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x}$$

- $\frac{\partial \mathbf{x}}{\partial \mathbf{x}} = \mathbf{I}$ ,  $\det(c\mathbf{A}) = c^n \det \mathbf{A}$  を用いた.

# 偶関数, 奇関数の積分 (多変数関数)

- $\mathbf{a} = (a_1, a_2, \dots, a_n)^\top$  として,  $-\mathbf{a}$  から  $\mathbf{a}$  までの  $f(\mathbf{x})$  の積分は,

$$\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x} = \int_{\mathbf{a}}^{\mathbf{0}} f(-\mathbf{y})(-1)^n d\mathbf{y} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) d\mathbf{x} \quad (\mathbf{y} = -\mathbf{x})$$

- 第一項は, 次と同じことである:

$$\begin{aligned} \int_{\mathbf{a}}^{\mathbf{0}} f(-\mathbf{y})(-1)^n d\mathbf{y} &= \int_{a_1}^0 \int_{a_2}^0 \cdots \int_{a_n}^0 f(-\mathbf{y})(-1)^n dy_1 dy_2 \cdots dy_n \\ &= \int_0^{a_1} \int_0^{a_2} \cdots \int_0^{a_n} f(-\mathbf{y}) dy_1 dy_2 \cdots dy_n \\ &= \int_{\mathbf{0}}^{\mathbf{a}} f(-\mathbf{y}) d\mathbf{y} \end{aligned}$$

- 積分範囲を入れ替えると, 符号が反転することに注意 (上では  $n$  回入れ替える).

# 偶関数, 奇関数の積分 (多変数関数)

- $\mathbf{a} = (a_1, a_2, \dots, a_n)^\top$  として,  $-\mathbf{a}$  から  $\mathbf{a}$  までの  $f(\mathbf{x})$  の積分は,

$$\begin{aligned}\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x} &= \int_{-\mathbf{a}}^{\mathbf{0}} f(\mathbf{x}) \, d\mathbf{x} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x} \\ &= \int_{\mathbf{a}}^{\mathbf{0}} f(-\mathbf{y})(-1)^n \, d\mathbf{y} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x} \quad (\mathbf{y} = -\mathbf{x}) \\ &= \int_{\mathbf{0}}^{\mathbf{a}} f(-\mathbf{y}) \, d\mathbf{y} + \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x}\end{aligned}$$

- 偶関数なら  $f(-\mathbf{x}) = f(\mathbf{x})$ , 奇関数なら  $f(-\mathbf{x}) = -f(\mathbf{x})$  だから,

$$\int_{-\mathbf{a}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x} = \begin{cases} 2 \int_{\mathbf{0}}^{\mathbf{a}} f(\mathbf{x}) \, d\mathbf{x} & (f(\mathbf{x}) \text{ が偶関数}) \\ 0 & (f(\mathbf{x}) \text{ が奇関数}) \end{cases}$$



# ガウス積分

## ガウス積分の基本形

$$\int_0^{\infty} \exp(-x^2) dx = \frac{\sqrt{\pi}}{2}$$

上記の積分を  $I$  とおくと,  $I^2$  は

$$I^2 = \int_0^{\infty} \int_0^{\infty} \exp(-(x^2 + y^2)) dx dy$$

$x = r \cos \theta$ ,  $y = r \sin \theta$  のように変数変換すると, ヤコビアンは

$$\begin{aligned} \left| \det \frac{\partial(x, y)}{\partial(r, \theta)} \right| &= \left| \det \begin{pmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{pmatrix} \right| = \left| \det \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix} \right| \\ &= |r (\cos^2 \theta + \sin^2 \theta)| = |r| \end{aligned}$$

# ガウス積分

$x = r \cos \theta$ ,  $y = r \sin \theta$ ,  $x, y \in [0, \infty]$  であるから,  $r \in [0, \infty)$ ,  $\theta \in [0, \frac{\pi}{2}]$ .

ヤコビアンは  $|r| = r$  であるから,  $dx dy = r dr d\theta$ .

以上より,  $I^2$  は

$$\begin{aligned} I^2 &= \int_0^\infty \int_0^\infty \exp(-(x^2 + y^2)) \, dx \, dy \\ &= \int_0^\infty \int_0^{\frac{\pi}{2}} \exp(-r^2) \, r \, dr \, d\theta = \int_0^{\frac{\pi}{2}} d\theta \int_0^\infty \exp(-r^2) \, r \, dr \\ &= \frac{\pi}{2} \left[ -\frac{1}{2} \exp(-r^2) \right]_0^\infty = \frac{\pi}{4} \end{aligned}$$

であるから,  $I = \frac{\sqrt{\pi}}{2}$ .

# ガウス積分

## ガウス積分の基本形

$$\int_{-\infty}^{\infty} \exp(-x^2) dx = \sqrt{\pi}$$

上記の積分を  $I$  とおくと,  $I^2$  は

$$I^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \exp(-(x^2 + y^2)) dx dy$$

$x = r \cos \theta$ ,  $y = r \sin \theta$  のように変数変換すると, ヤコビアンは  $r$ . よって,  $dx dy = r dr d\theta$ .  $x, y \in (-\infty, \infty)$  であるから,  $r \in [0, \infty]$ ,  $\theta \in [0, 2\pi]$ .

$$\begin{aligned} I^2 &= \int_0^{\infty} \int_0^{2\pi} \exp(-r^2) r dr d\theta = \int_0^{2\pi} d\theta \int_0^{\infty} \exp(-r^2) r dr \\ &= 2\pi \left[ -\frac{1}{2} \exp(-r^2) \right]_0^{\infty} = \pi \quad \longrightarrow \quad I = \sqrt{\pi} \end{aligned}$$

# ガウス積分

## ガウス積分の基本形

$$\int_0^{\infty} \exp(-x^2) dx = \frac{\sqrt{\pi}}{2}$$
$$\int_{-\infty}^{\infty} \exp(-x^2) dx = \sqrt{\pi}$$

$\exp(-x^2)$  は偶関数 ( $f(x) = f(-x)$ ) であるから,  $-\infty$  から  $\infty$  までの積分値は, 0 から  $\infty$  までの積分値の倍となる.

# ガウス積分

## ガウス積分の基本形

$$\int_0^{\infty} \exp(-ax^2) dx = \frac{1}{2} \sqrt{\frac{\pi}{a}} \quad (a > 0)$$

$$\int_{-\infty}^{\infty} \exp(-ax^2) dx = \sqrt{\frac{\pi}{a}} \quad (a > 0)$$

$y = \sqrt{ax}$  とすると,  $x = \frac{y}{\sqrt{a}}, \frac{dx}{dy} = \frac{1}{\sqrt{a}}$  だから,

$$\int_0^{\infty} \exp(-ax^2) dx = \int_0^{\infty} \exp(-y^2) \frac{dx}{dy} dy = \frac{1}{\sqrt{a}} \int_0^{\infty} \exp(-y^2) dy = \frac{1}{\sqrt{a}} \frac{\sqrt{\pi}}{2}$$

$\exp(-ax^2)$  は偶関数だから, 積分範囲を  $[0, \infty)$  から  $(-\infty, \infty)$  に広げると, 積分値は倍となる.

# ガウス積分

## ガウス積分の基本形

$$\int_0^{\infty} x \exp(-ax^2) dx = \frac{1}{2a} \quad (a > 0)$$
$$\int_{-\infty}^{\infty} x \exp(-ax^2) dx = 0 \quad (a > 0)$$

次のように計算できる:

$$\int_0^{\infty} x \exp(-ax^2) dx = \left[ -\frac{1}{2a} \exp(-ax^2) \right]_0^{\infty} = \frac{1}{2a}$$

$x \exp(-ax^2)$  は奇関数だから,  $-\infty$  から  $\infty$  までの積分は 0.

# ガウス積分

## ガウス積分の漸化式

$$I_n = \int_0^{\infty} x^n \exp(-ax^2) dx \text{ とおくと } (a > 0),$$

$$I_{n+2} = \frac{n+1}{2a} I_n$$

次のように部分積分すれば ( $\lim_{x \rightarrow \infty} x^n \exp(-x) = 0$  に注意):

$$\begin{aligned} I_n &= \int_0^{\infty} x^n \exp(-ax^2) dx \\ &= \left[ \frac{x^{n+1}}{n+1} \exp(-ax^2) \right]_0^{\infty} + \frac{2a}{n+1} \int_0^{\infty} x^{n+2} \exp(-ax^2) dx \\ &= \frac{2a}{n+1} \int_0^{\infty} x^{n+2} \exp(-ax^2) dx = \frac{2a}{n+1} I_{n+2} \end{aligned}$$

# ガウス積分

## ガウス積分の漸化式

$$I_n = \int_0^{\infty} x^n \exp(-ax^2) dx \text{ とおくと } (a > 0),$$

$$I_{n+2} = -\frac{\partial}{\partial a} I_n$$

次のように計算できる:

$$\begin{aligned} \frac{\partial}{\partial a} I_n &= \frac{\partial}{\partial a} \int_0^{\infty} x^n \exp(-ax^2) dx \\ &= \int_0^{\infty} \frac{\partial}{\partial a} x^n \exp(-ax^2) dx \\ &= -\int_0^{\infty} x^{n+2} \exp(-ax^2) dx = -I_{n+2} \end{aligned}$$

微分と積分の交換については条件がある (上の場合は可能).



# ガウス積分

## ガウス積分 (2 乗)

$$\int_0^{\infty} x^2 \exp(-ax^2) dx = \frac{1}{4} \sqrt{\frac{\pi}{a^3}} \quad (a > 0)$$

$$\int_{-\infty}^{\infty} x^2 \exp(-ax^2) dx = \frac{1}{2} \sqrt{\frac{\pi}{a^3}} \quad (a > 0)$$

$$I_n = \int_0^{\infty} x^n \exp(-ax^2) dx \text{ とすると, } I_{n+2} = \frac{n+1}{2a} I_n \text{ である.}$$

$$I_0 = \int_0^{\infty} \exp(-ax^2) dx = \frac{1}{2} \sqrt{\frac{\pi}{a}} \text{ だから,}$$

$$I_2 = \int_0^{\infty} x^2 \exp(-ax^2) dx = \frac{0+1}{2a} I_0 = \frac{1}{2a} \frac{1}{2} \sqrt{\frac{\pi}{a}} = \frac{1}{4} \sqrt{\frac{\pi}{a^3}}$$

$x^2 \exp(-ax^2)$  は偶関数なので,  $(-\infty, \infty)$  の積分は,  $[0, \infty)$  の積分の 2 倍.

# ガウス積分

## ガウス積分 (3 乗)

$$\int_0^{\infty} x^3 \exp(-ax^2) dx = \frac{1}{2a^2} \quad (a > 0)$$

$$\int_{-\infty}^{\infty} x^3 \exp(-ax^2) dx = 0 \quad (a > 0)$$

$$I_n = \int_0^{\infty} x^n \exp(-ax^2) dx \text{ とすると, } I_{n+2} = \frac{n+1}{2a} I_n \text{ である.}$$

$$I_1 = \int_0^{\infty} x \exp(-ax^2) dx = \frac{1}{2a} \text{ だから,}$$

$$I_3 = \int_0^{\infty} x^3 \exp(-ax^2) dx = \frac{1+1}{2a} I_1 = \frac{1}{a} \frac{1}{2a} = \frac{1}{2a^2}$$

$x^3 \exp(-ax^2)$  は奇関数だから,  $-\infty$  から  $\infty$  までの積分は 0.

# ガウス積分

## ガウス積分 (二次関数の一般形)

$$\int_{-\infty}^{\infty} \exp(-ax^2 + bx + c) dx = \exp\left(\frac{b^2}{4a} + c\right) \sqrt{\frac{\pi}{a}}$$

$-ax^2 + bx + c = -a\left(x - \frac{b}{2a}\right)^2 + \frac{b^2}{4a} + c$  と平方完成できる。

$y = x - \frac{b}{2a}$  とすると,  $\frac{\partial x}{\partial y} = 1$ , 積分範囲は  $(-\infty, \infty)$  だから,

$$\begin{aligned} \int_{-\infty}^{\infty} \exp(-ax^2 + bx + c) dx &= \exp\left(\frac{b^2}{4a} + c\right) \int_{-\infty}^{\infty} \exp(-ay^2) \frac{\partial x}{\partial y} dy \\ &= \exp\left(\frac{b^2}{4a} + c\right) \int_{-\infty}^{\infty} \exp(-ay^2) dy = \exp\left(\frac{b^2}{4a} + c\right) \sqrt{\frac{\pi}{a}} \end{aligned}$$